



厚德弘毅 求是笃行

High Precision and Efficient Anonymous Traffic Classification in the Real-World

- 发布: IEEE TON 2025 • 作者: Hantao Mei, Guang Cheng
- 日期: 2026.4.23





在线与离线分类的博弈

存储与计算开销

存储与计算开销





本研究的背景聚焦于现实开放世界中 Tor 等匿名工具的流量分类（TC）挑战。虽然现有的流量分类方法在封闭场景中表现极佳，但在真实的大规模网络设备中部署时，往往会陷入“基率谬误”（Base Rate Fallacy）。由于真实世界中 Tor 流量的占比极低，即使分类器的误报率很小，也会产生数量庞大的假阳性（误报）样本，导致分类结果完全不可靠。因此，本文旨在提出一种能在实际大规模网络中高效、高精度识别匿名流量的解决方案。

基率谬误 Base Rate Fallacy (r)

基率谬误指的是：在目标类本来极少时，即使模型误报率很低，最终也会被大量负样本基数放大。

论文举例：一个 **Tor** 二分类器召回率 100%、precision 99.9%，看起来已经非常强。

但若 $\text{non-Tor/Tor} = 1000$ ，那么每 1000 条普通流错报 1 条 **Tor**，累计后会带来与真阳性同量级的假阳性。

结果是实验指标很好看，但真实 precision 可能只剩 50%，分类结果不再可信。

传统离线 precision 为 $P2 = TP / (TP + WP + FP)$ ，默认测试集类比例就是真实比例。

作者指出，当 non-Target/Target 的比值为 r 时，FP 会被真实环境放大 r 倍。

因此他们使用 B-precision: $TP / (TP + WP + r \cdot FP)$ ，直接把基率纳入指标。

Recall 则写成 $R1 \cdot R2$ ，分别反映在线和离线两个阶段的召回贡献。

这套指标能更真实地衡量“部署之后结果是否可信”。

TABLE I
HOW WE COUNT THE METRICS IN HPETC


Classified \ True	Target			non-Target
	Correct Target	Wrong Target	non-Target	
Target	N_{TP}^2	N_{WP}^2	N_{FN}^2	N_{FN}^1
non-Target	-	N_{FP}^2	N_{TN}^2	N_{TN}^1


N_{FN}^1, N_{TN}^1 : Result of online identification.

$N_{TP}^2, N_{WP}^2, N_{FN}^2, N_{FP}^2, N_{TN}^2$: Result of offline classification.

$$B - precision = P'_2 = \frac{N_{TP}^2}{N_{TP}^2 + N_{WP}^2 + r \cdot N_{FP}^2}$$

$$recall = \frac{N_{TP}^1}{N_{TP}^1 + N_{FN}^1} \cdot \frac{N_{TP}^2}{N_{TP}^2 + N_{WP}^2 + N_{FN}^2} = R_1 \cdot R_2$$






先按五元组把 TCP 包聚合成 flow，再把双向通信组织成 bifold。

对每条流量，只取 A、B 两个方向各前 20 个包，也就是 $N = 20$ 。

从这些包中提取顺序特征：包长 PL 与包间到达时间 IAT 。

最终形成在线特征向量 U ，在线分类器做的是二分类：Target Tor / Non-Target。

只有被预测为 Target Tor 的流量才进入过滤器并写入离线 pcap，其他大部分普通流直接放过。



离线模块从完整流量中提取统计特征，包括包数、长度统计、时间间隔统计等。

作者不是无限加特征，而是用随机森林的信息增益做特征排序，最终保留 60 个最重要特征。

在类型分类任务里，离线分类器输出 8 类：7 类 Tor 业务 + 1 类 non-Tor。

在网站指纹任务里，离线阶段识别 100 个目标网站，因此难度更高。

作者受 Borderline-SMOTE 启发, 不再平均地过采样, 而是专门关注边界样本。

先按近邻关系把目标类样本分成 safe、boundary、noise 三类。

只有位于 Target 和 non-Target 交界处的 boundary 样本, 才是最值得增强的对象。

沿着边界样本与其近邻之间生成合成样本, 可以强化分类器对“模糊地带”的学习能力。

Algorithm 1 Boundary Samples Generation

Input: origin training set T , parameter for delimiting samples m , parameter for generate samples k , expected Target sample size $snum$, sample generation factor r_j ;

Output: borderline enhanced training set T' ;

Initialization: $T' = T$, marker Target samples $T_{Tar} = \{f_1, f_2, \dots, f_{Tar}\}$, non-Target samples $T_{Ntar} = \{f_1, f_2, \dots, f_{Ntar}\}$ Noise = {}, Boundary = {}, Safe = {};

Step 1: boundary sample identification

- 1: for f_i in T_{Tar} do
- 2: calculate s nearest neighbors for f_i , the number of non-Target samples among the s neighbors is denoted by s' ($0 \leq s' \leq s$);
- 3: if $s' = s$ then add f_i to Noise;
- 4: else if $\frac{s}{2} < s' < s$ then add f_i to Boundary;
- 5: else if $0 < s' < \frac{s}{2}$ then add f_i to Safe;

Step 2: boundary sample generations

- 6: $h = \frac{snum}{num(Boundary)}$;
- 7: for f'_i in Boundary do
- 8: calculate k nearest neighbors for f'_i from T_{Tar} ;
- 9: select h samples randomly from k nearest neighbors;
- 10: calculate differences between f'_i and these samples, $diff_j = \{d_1, d_2, \dots, d_h\}$;
- 11: for $j = 1, 2, \dots, h$ do
- 12: $synthetic_j = f'_i + r_j \times diff_j$;
- 13: add $synthetic_j$ to T' ;

return T' .

在线阶段会把一部分 non-Tor 样本误送进离线阶段，而这批样本恰好是最像目标类的负样本。

如果离线分类器仍按理想平衡分布训练，它就看不到真实部署中最容易产生假阳性的部分。

USET 把训练数据拆成三类：Target、普通 non-Target、以及“被在线阶段误送的 non-Target”。

然后通过迭代加权与重组训练集，让模型重点学习最危险的误送负样本。


该算法的灵感来源于 Adaboost 算法

Algorithm 2 Unbiased Sample Enhanced Technique Classifier Training

Input: all training set: Target Tor set S_{Tar} , non-Target set S_{Ntar} , misclassified non-Target set $S_{MisNtar}$;

Output: optimized classifier $G(x)$;

- 1: select n samples from S_{Tar} , S_{Ntar} and $S_{MisNtar}$ respectively to form the initial training set T_1 ;
 - 2: set initialize weight $D_1 = \{w_{11}, w_{12}, \dots, w_{1,3n}\}$, equal weights for each sample;
 - 3: **for** $r = 1, 2, \dots, R$ **do**
 - 4: training the classifier $G_r(x)$ with T_r ;
 - 5: calculate the difference $e_r = P(G_r(x_i) \neq y_i) = \sum_i w_{ri} I(G_r(x_i) \neq y_i) = \sum_i w_{ri}$;
 - 6: **if** $e_r > 0.5$ **then** $a_r = 0$;
 - 7: **else** $a_r = \frac{1}{2} \ln \frac{1-e_r}{e_r}$;
 - 8: update weight, $D_{r+1} = \{w_{r+1,1}, \dots, w_{r+1,3n}\}$,
 $w_{(r+1,i)} = \frac{w_{ri}}{Z_r} \exp(-a_r y_i G_r(x_i))$, which $Z_r = \sum_i w_{ri} \exp(-a_r y_i G_r(x_i))$;
 - 9: calculate the weight sum of non-Target sets $W_r^{Ntar} = \sum_i w_i (z_i = Ntar)$, $W_r^{MisNtar} = \sum_i w_i (z_i = MisNtar)$;
 - 10: modify the sample composition by adding or removing instances from T_r^{Ntar} and $T_r^{MisNtar}$ to ensure
 $D_{Ntar} = D_{MisNtar}$;
 - 11: $T_{r+1} = T_1^{Tar} \cup T_{r+1}^{Ntar} \cup T_{r+1}^{MisNtar}$;
- return** $G_r(x)$.



作者最终选出四个表现最好的分类器：Decision Tree(C45)、KNN、RF、CNN，并对它们做投票集成。


NAIVE: 多数票；

SLIGHTLY: 若共识票数不足 3，则直接判为 non-Target；

STRONG: 更严格地优先拒绝。

把“分类器之间的不一致”解释为低置信度，这非常适合低基率安全场景。

MVET 会损失少量 recall，但可以显著提升 B-precision，本质上是在用召回换真实可用性。



BDET 作用在样本层面：把最容易出错的边界样本补充出来。

USET 作用在训练分布层面：让离线分类器更关注在线阶段最容易误送的负样本。

MVET 作用在决策层面：把不确定样本主动打回 **non-Target**，形成保守高置信输出。

三者分别作用于“数据、训练、决策”三个层面，因此组合后效果最好。

数据集分为 Type dataset 和 Website dataset，另有超大规模 normal traffic 作为非目标集。

对比对象既包括已有 SOTA 方法，也包括作者自己训练的单独在线与单独离线基线。

每组实验执行 10 次取平均，避免偶然波动影响结论。

重点考察两种比值： $r = 20$ （中等失衡）与 $r = 1000$ （极端失衡）。

TABLE II
BREAKDOWN OF TRAFFIC COUNTS IN OUR DATASET


Dataset	Type dataset							Website dataset		normal
Class	audio	browser	mail	P2P	message	vedio	VoIP	top100	next10,000	
number	1674	17687	9053	5666	3797	2514	24439	100×200	10,000×1	-
train	1474	5000	5000	5000	3597	2314	5000	100×180	9000	5000
test	200	200	200	200	200	200	200	100×20	1000	2 million

类型数据集包含 7 类 Tor 业务流量，单类样本数从几千到两万多不等，其中 VoIP 和 browser 相对更多，video 较少。


网站数据集包含 Alexa top100 网站，每站访问 200 次；另选取 next10,000 网站，每站 1 次。

最关键的是 normal traffic 测试集达到 200 万条，这使得低基率评估更有意义。

收集200万条来自各种用户的日常数据流。7台配备了 Tor obfs4网桥的电脑自动生成 Tor流量。利用Linux内核的‘inotify’函数监控Tor日志文件，仅在捕捉到obfs4链接成功信号后，才开始自动化收集流量



(a) $r = 20$




(b) $r = 1000$

$r=20$ 时，很多方法的 B-precision 还能维持在中高水平。


但一到 $r=1000$ ，传统方法 B-precision 几乎全部崩掉，很多低于 10%。

未增强的 HPETC (NET) 已能达到 51.84%，说明“两阶段框架”本身就有价值。

集成三种增强技术后，HPETC 在 $r=1000$ 时仍能保持超过 90% 的 B-precision。



(a) $r = 20$



(b) $r = 1000$

在 $r=20$ 时，最优 BDET 可达到 95.8%；在 $r=1000$ 时可达到 71.06%。

离线阶段当生成更多 non-Target 边界样本时，分类器会更保守，误把普通流判成目标流的概率更低。

结论是：BDET 尤其适合对抗极低基率场景中的边界误判。




Fig. 6. B-precision of unenhanced HPETC (NET) and Unbiased Sample Enhanced Technique in HPETC (USET).




Fig. 7. Confusion matrices (percentage precision) of Random Forest (RF) and CNN using Unbiased Sample Enhanced Technique at $r = 1000$.

USET 在 $r=20$ 与 $r=1000$ 下都能提升各类模型的 B-precision。

论文特别指出， $r=20$ 时最高可达 96.17%， $r=1000$ 时 CNN 仍达到 78.34%。

混淆矩阵显示最容易混淆的类别被明显压缩，说明模型真的学会了“危险负样本”。




Fig. 8. Results of Multi-voting Enhanced Technique.

在 $r=20$ 时，NAIVE 与 STRONG 兼顾较高 B-precision 和 recall；SLIGHTLY 更偏向 precision。

在 $r=1000$ 时，SLIGHTLY 可把 B-precision 提升到 86.43%，只付出约 9.95% recall 损失。

三种 ET 集成后，论文给出：SLIGHTLY 策略下 B-precision 93.24%、recall 92.64%。

若使用 STRONG，B-precision 可到 94.96%，但 recall 损失明显更大，因此更适合极端高 r 场景。




Fig. 9. B-precision and recall of website fingerprinting on HPETC at $r = 1000$.

在 $r=1000$ 的网站指纹任务中，多数 SOTA 方法和 NET 的 B-precision 都极低。

HPWF 已经是偏高精度取向的方法，B-precision 约为 75.3%。

而三种 ET 全部集成后的 HPETC 可达到 81.12%，并且 recall 只小幅下降。

这说明 HPETC 不是只对某一种任务有效，而是对开放世界匿名流量分析具有通用性。



TABLE IV

COMPARISON OF METHODS FOR NET AND HPETC AT $\tau = 1000$

Methods	NET			HPETC		
	B-pre.	Rec.	Acc. ₂	B-pre.	Rec.	Acc. ₂
Wa-kNN	1.12	88.42	79.67	57.89	88.52	68.06
CUMUL	8.68	23.26	99.17	89.48	22.65	61.17
kFP	1.97	94.42	87.79	71.19	93.64	80.42
DLWF-SDAE	0.59	91.39	56.67	69.12	84.00	79.47
DLWF-LSTM	1.59	83.95	85.28	68.56	84.62	78.94
DLWF-CNN	1.52	90.14	83.53	67.33	89.48	76.71
RF	7.22	99.05	96.69	86.28	98.48	92.17
TMWF	5.93	95.65	95.71	91.21	97.79	94.78
Tik-Tok-UN	1.81	89.46	86.32	67.56	89.65	77.45
Tik-Tok-WP	0.37	75.35	66.24	51.46	75.10	58.43

在 NET 场景下, 大多数 WF 方法的 B-precision 都非常低, 最高的 TMWF 也只有 5.93%。

放入 HPETC 后, Wa-kNN、CUMUL、kFP、DLWF、RF、TMWF 等都获得大幅提升。

其中 TMWF 在 HPETC 下达到 91.21% 的 B-precision, RF 达到 86.28%, Tik-Tok-WP 防御场景也提升到 51.46%。

这证明 ET 与框架结构本身具有独立价值, 可以增强多种离线模型。




Fig. 10. Precision of online classifier (center bars), the ratio of filtered flows (left bars) and the ratio of filtered traffic size (right bars) with error bars representing the upper and lower limits of flow savings at $r = 1000$.

即使是未增强的 **NET**，也能提前过滤大量无关流量，减少离线阶段负担。

三种 **ET** 集成后，在线分类器实际 **precision** 达到 **84.14%**。

在最优情况下，离线阶段每处理 1 条流，在线阶段已经过滤掉 **737** 条流。

按论文估算，在大包场景下，存储收益可超过 **860k**，也就是每转发 **1kb** 给离线阶段，就可能提前过滤 **860Mb** 普通流量。




Fig. 11. The variation of B-precision of different methods when we vary r from 1 to 1000.

简单场景“censorship”：统计志愿者日常浏览中被审查页面比例，得到 r 范围 5.69 到 32.45，平均 14.58，因此取 $r=20$ 。

复杂场景“flow”：在真实校园网关上测量 Tor 流量相对总流量的比例， r 范围 170 到 3109，因此取 $r=1000$ 。

这说明论文设置的两个 r 值都来自现实测量，而不是拍脑袋假设。

左图还显示，随着 r 从 1 提升到 1000，HPETC 的 B-precision 只从 $>96.02\%$ 下降到约 94.9%，鲁棒性非常强。

第一，当前 HPETC 仍较依赖人工特征与专家知识，而不是完全自动的深度特征学习。

第二，在低基率下要做到高精度本来就很难；如果再叠加强流量防御，如 padding、recombination，性能仍可能下降。

第三，论文出于伦理和安全考虑，只考虑了被动监听型攻击者；现实攻击者还可能联合 DNS、长期观察等额外信息进一步提升去匿名能力。

因此 HPETC 很强，但并不是“已经彻底解决匿名流量分析问题”，而是把真实部署标准向前推进了一大步。





厚德弘毅 求是笃行

南京邮电大学

欢迎老师和同学批评指正！

